Google Colab ... for Data Science

Cleaning and treatment of an .csv

This plataform alows me to work with other people for cleaning and search for data in real time. Also all the files that are involved in the projetcs are loaded in the cloud, so anyone with acces can work in diffrent places

Importo las librerias

```
1 import pandas as pd
2 import numpy as np
```

- Accedo a un drive con documentos compartidos

```
1 from google.colab import drive
2 drive.mount('/content/drive')
3
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.m
```

- Conecto el archivo con una ruta que pueda leer Pandas

```
1 ruta = '/content/drive/MyDrive/Colab Notebooks/Archivos para montar/2023_vehicular_tr
```

- Cargo el archivo a un DataFrame creado con Pandas para poder manipularlo

```
1 df = pd.read_csv(ruta)
```

- Extraccion de primera informacion clave a tener encuenta. Cuantas entradas hay, cuales son mis columnas, que tipos de datos tienen. Imprimo las primeras o las últimas entradas

```
1 df.info()
2 df.describe()
3 df.head()
4 df.tail()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 534571 entries, 0 to 534570
Data columns (total 7 columns):
 #   Column      Non-Null Count   Dtype 
---  ------      --------------   ----- 
 0   MES         534571 non-null  int64 
 1   DIA         534571 non-null  int64 
 2   HORA        534571 non-null  int64 
 3   ID_PEAJE    534571 non-null  object
 4   SENTIDO     534571 non-null  object
 5   TIPO_COBRO  534571 non-null  object
 6   PASOS       534571 non-null  int64 
dtypes: int64(4), object(3)
memory usage: 28.5+ MB
```

	MES	DIA	HORA	ID_PEAJE	SENTIDO	TIPO_COBRO	PASOS
534566	12	31	23	SAR	Provincia	Tag	13
534567	12	31	23	PB3	Provincia	Violación	2
534568	12	31	23	PB4	Centro	Violación	7
534569	12	31	23	SAR	Provincia	Violación	6
534570	12	31	23	PB1	Provincia	Tag	1

- A traves de Pandas busco si hay algún dato tuplicado que sea necesario eliminar. Imprimo los duplicados si los hubiera

```
1 duplicados = df.duplicated()
2 df[duplicados]
```

	MES	DIA	HORA	ID_PEAJE	SENTIDO	TIPO_COBRO	PASOS

- A traves de Pandas busco si hay algún dato nulo que sea necesario eliminar.

```
1 df.isnull().sum()
```

	0
MES	0
DIA	0
HORA	0
ID_PEAJE	0
SENTIDO	0
TIPO_COBRO	0
PASOS	0

dtype: int64

- Imprimo los nulos que pudiera haber para decidir que hacer

```
1 df[df.isnull().any(axis=1)]
```

	MES	DIA	HORA	ID_PEAJE	SENTIDO	TIPO_COBRO	PASOS

- Visualizacion de aquellas columnas string de categoria, para saber cuantos unicos hay, y si hay errores en ellas. Luego decidir

```
1 df['SENTIDO'].unique()
2 df['SENTIDO'].value_counts()
```

SENTIDO	count
Provincia	300100
Centro	234470
Provincia	1

dtype: int64

- Si tengo que limpiar errores, como espacios al comienzo o al final, opero con la columna

```
1 df['SENTIDO'] = df['SENTIDO'].str.strip()
```

- Corroboro la limpieza

```
df['SENTIDO'].unique()
df['SENTIDO'].value_counts()
```

SENTIDO	count
Provincia	300101
Centro	234470

dtype: int64

```
df['TIPO_COBRO'].unique()
df['TIPO_COBRO'].value_counts()
```

TIPO_COBRO	count
Tag	130127
Violación	129394
Mercado Pago	124278
Efectivo	40051
Exento	39874
Rec.Deuda	37144
Tarjeta Magnética	14633
N/D	8690
REC DEUDA	5176
DEMORAS	5109
CPP	95

dtype: int64

- Con la limpieza corroborada guardo en el Drive o en la Unidad

```
ruta_guardado ='/content/drive/MyDrive/peajes_buenos_aires_limpio.csv'
df.to_csv(ruta_guardado, index=False)

from google.colab import files
df.to_csv('peajes_limpio.csv', index=False)
files.download('peajes_limpio.csv')
```

Este proyecto explora y limpia un conjunto de datos de tránsito proveniente de peajes de Buenos Aires. A través de Python y Google Colab, se realizó la depuración del archivo original (detección de nulos, valores inconsistentes, duplicados y errores de formato). Una vez estructurado el dataset, se llevaron a cabo visualizaciones exploratorias para identificar patrones temporales, distribuciones de medios de pago y comportamiento según peajes.

- Importar librerias para visualizaciones

```
import matplotlib.pyplot as plt
import seaborn as sns
```

- El siguiente ploteo de barras cuenta la frecuencia de entrada de cada categoria. No vincula con el condenido de otra columna

```
plt.figure(figsize=(10,6))
sns.barplot(x=df['ID_PEAJE'].value_counts().index,
            y=df['ID_PEAJE'].value_counts().values,
            palette='viridis')
plt.title('Cantidad total de pasos por peaje')
plt.xlabel('ID_PEAJE')
plt.ylabel('Cantidad de pasos')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

```
<ipython-input-15-3127008236>:2: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.

  sns.barplot(x=df['ID_PEAJE'].value_counts().index,
```

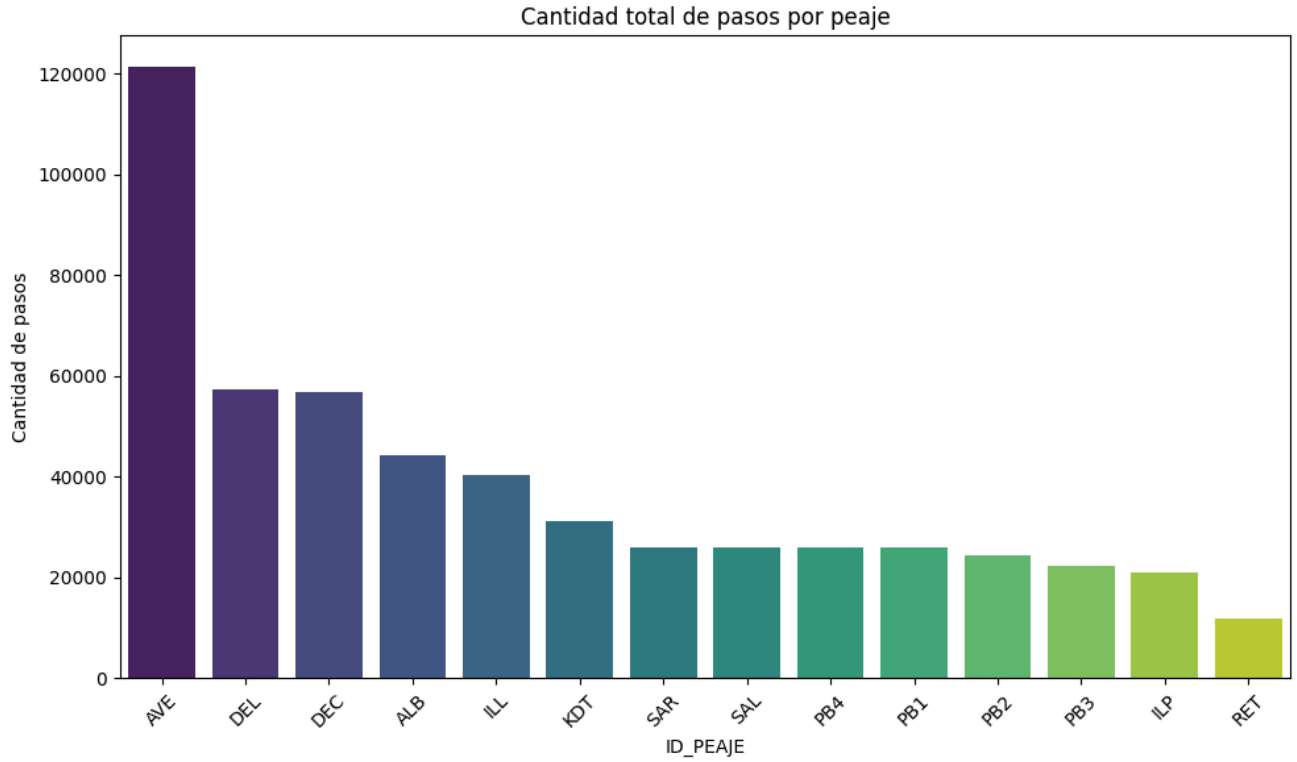

- Para observar la suma de otra columna, de cada categoria, hay que agrupar por categoria en un df aparte, y luego hacer la suma con otros codigos

```
pasos_por_peaje = df.groupby('ID_PEAJE')['PASOS'].sum().sort_values(ascending=False)
```

```
import matplotlib.pyplot as plt

plt.figure(figsize=(10,6))
pasos_por_peaje.plot(kind ='bar', color='skyblue')

bars = plt.bar(pasos_por_peaje.index, pasos_por_peaje.values, color='skyblue')

plt.xlabel('ID Peaje')
plt.ylabel('Total de pasos')
plt.xticks(rotation=45)
```

```
11
12 for bar in bars:
13     height = bar.get_height()
14     # Mostrar en millones (redondeado a 1 decimal)
15     plt.text(bar.get_x() + bar.get_width()/2.0, height, f'{height/1e6:.1f}M',
16              ha='center', va='bottom', fontsize=9)
17
18 plt.tight_layout()
19 plt.show()
```

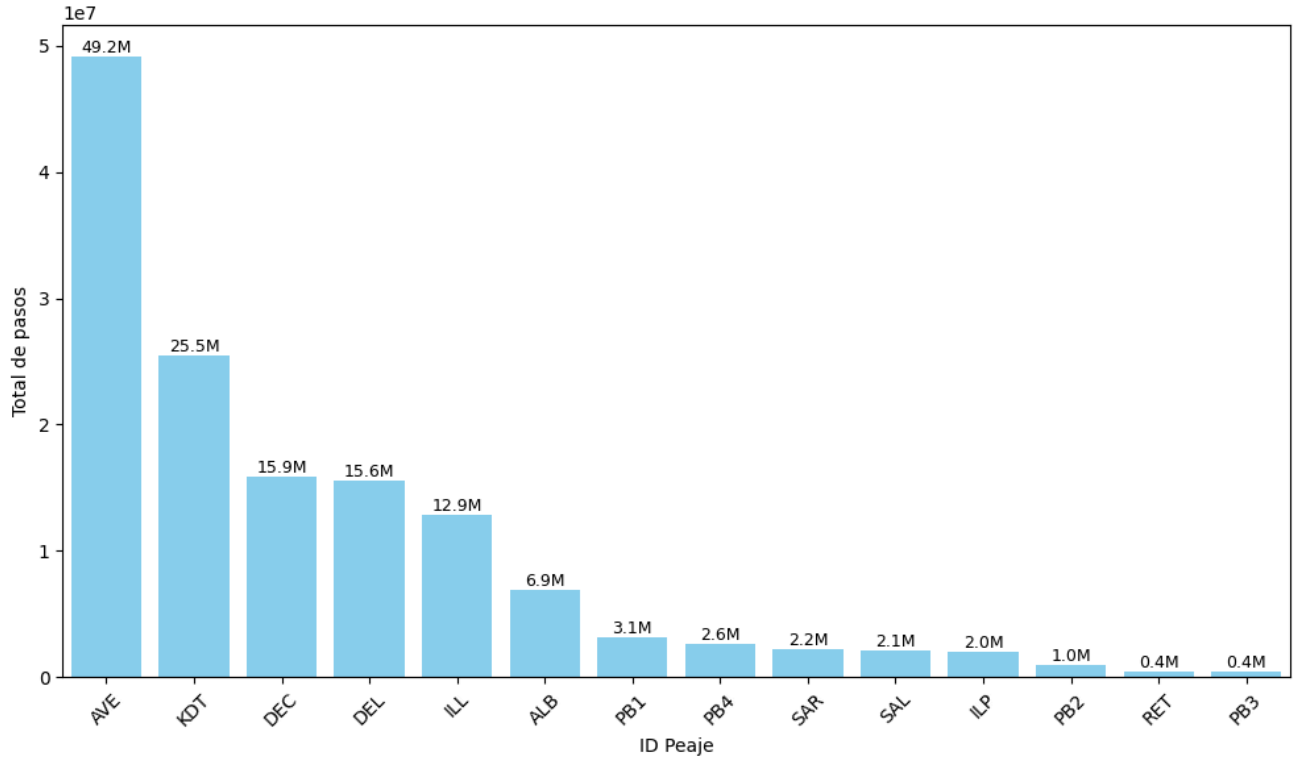

* Agrupar por horas

Obtencion de horas pico

```
1 pasos_por_hora = df.groupby('HORA')['PASOS'].sum().sort_index()
```

```
1 plt.figure(figsize=(12,6))
2 sns.lineplot(x=pasos_por_hora.index, y=pasos_por_hora.values)
3 plt.title('Cantidad total de pasos por hora del día')
```

```
plt.xlabel('Hora')
plt.ylabel('Pasos')
plt.xticks(range(0, 24))
plt.grid(True)
plt.tight_layout()
plt.show()
```

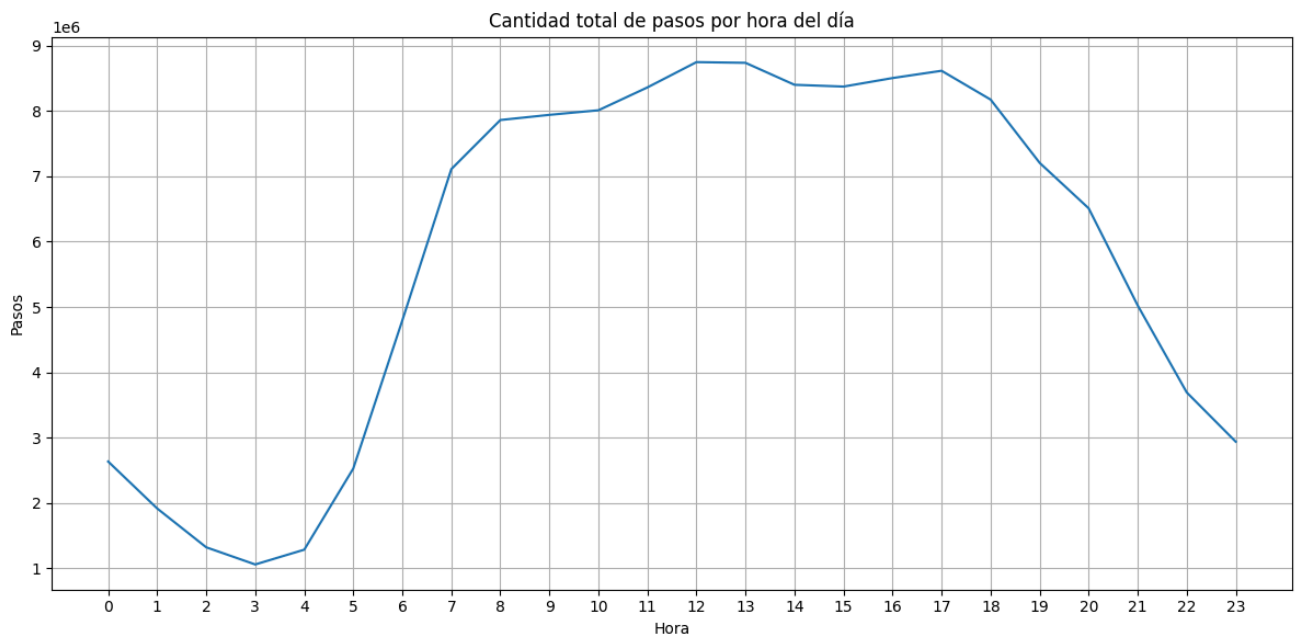

*Agrupamiento por Peaje y hora, sumando la cantidad de pasos. Entrega un data frame de tres columnas

```
pasos_por_hora_y_peaje = df.groupby(['ID_PEAJE', 'HORA'])['PASOS'].sum().reset_index(
```

```
plt.figure(figsize=(14,7))
sns.lineplot(data=pasos_por_hora_y_peaje, x='HORA', y='PASOS', hue='ID_PEAJE')

plt.title('Pasos por hora según peaje')
plt.xlabel('Hora del día')
plt.ylabel('Total de pasos')
plt.xticks(range(0, 24))
plt.legend(title='ID Peaje')
```

```
plt.grid(True)
plt.tight_layout()
plt.show()
```

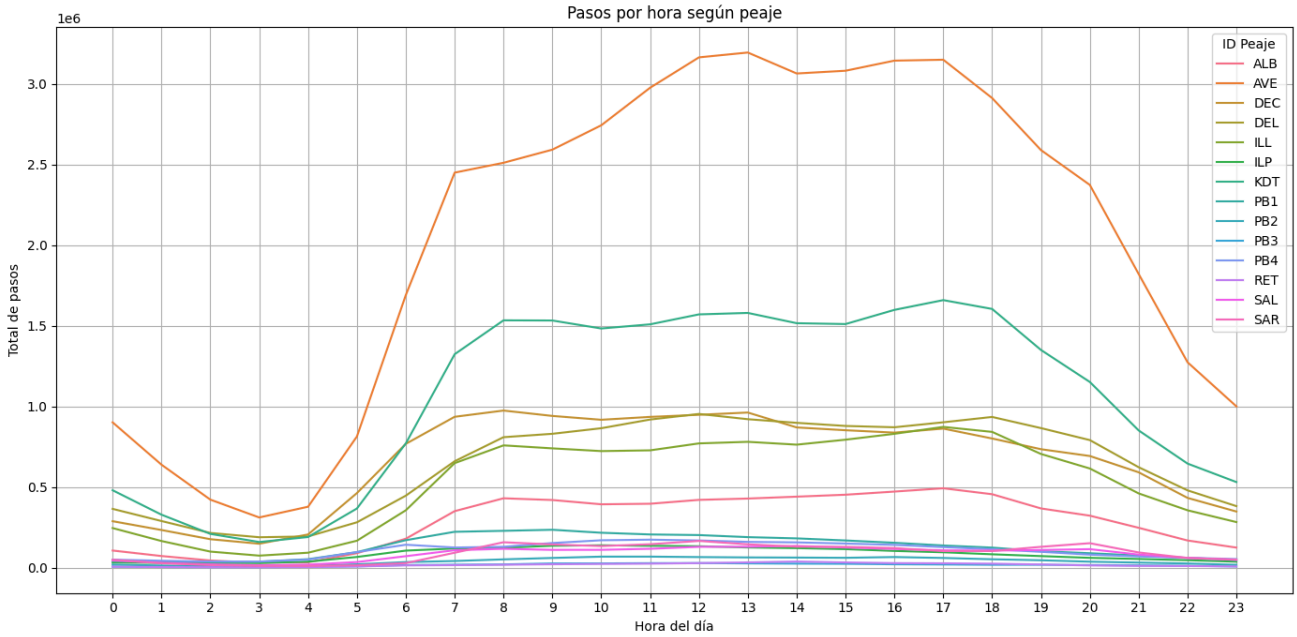

“A través del análisis de pasos por hora agrupados por ID de peaje, detecté distintos patrones de comportamiento. Algunos peajes presentan curvas horarias muy pronunciadas, con picos de tránsito claros en ciertas franjas horarias (horas pico), mientras que otros mantienen un flujo más uniforme durante todo el día. Esto permitió segmentar los peajes según su patrón de uso y sugiere posibles diferencias de localización o funcionalidad.”

```
rango_por_peaje = pasos_por_hora_y_peaje.groupby('ID_PEAJE')['PASOS'].agg(['min', 'ma
rango_por_peaje['rango'] = rango_por_peaje['max'] - rango_por_peaje['min']
rango_por_peaje = rango_por_peaje.sort_values(by='rango', ascending=False)
```

```
top_3_rango_alto = rango_por_peaje.head(3).index
top_3_rango_bajo = rango_por_peaje.tail(3).index
```

```
df_filtrado = pasos_por_hora_y_peaje[pasos_por_hora_y_peaje['ID_PEAJE'].isin(top_3_ra
```

```
plt.figure(figsize=(14,6))
sns.lineplot(data=df_filtrado, x='HORA', y='PASOS', hue='ID_PEAJE')
plt.title('Comparación de patrones horarios entre peajes con mayor y menor variabilid
plt.xlabel('Hora del día')
plt.ylabel('Cantidad de pasos')
plt.legend(title='ID Peaje')
plt.show()
```

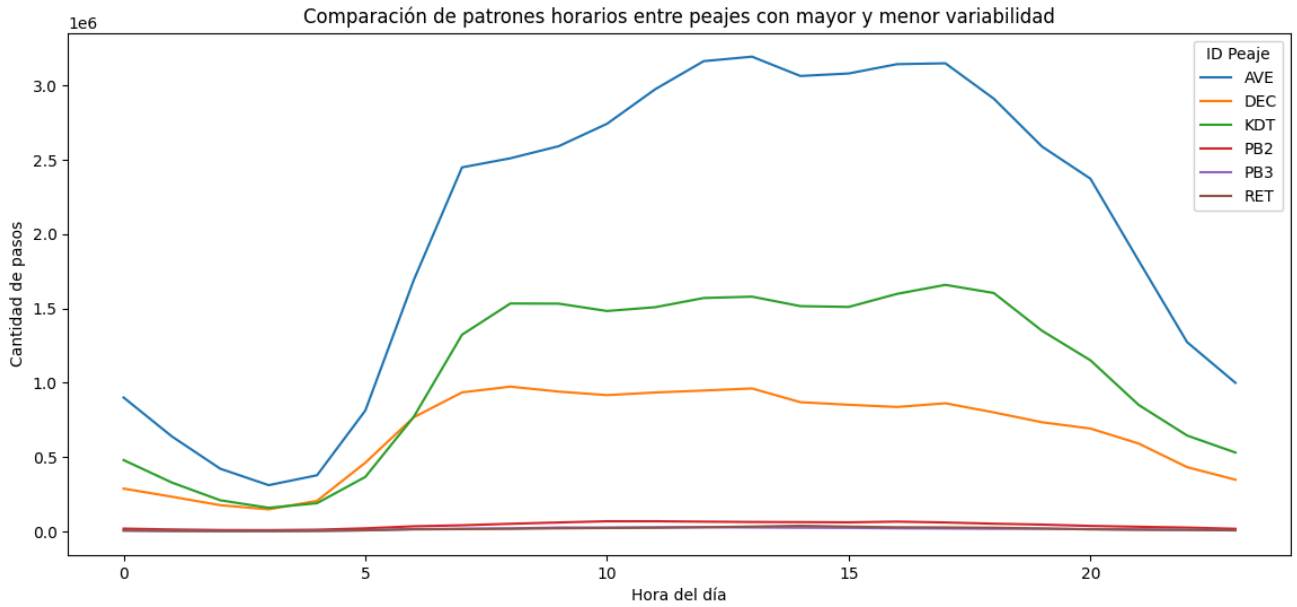

A partir del análisis de registros horarios de tránsito en los peajes de Buenos Aires, se clasificaron los peajes según su variabilidad horaria. Para ello se calculó el rango entre la cantidad máxima y mínima de pasos por hora registrados en cada peaje a lo largo del día.

El gráfico permite observar con claridad que algunos peajes presentan un rango amplio entre sus momentos de menor y mayor circulación, reflejando un patrón típico de hora pico, con flujos concentrados en horarios específicos (como ingreso o egreso laboral). Por el contrario, otros

peajes mantienen una distribución más estable a lo largo del día, sin picos marcados, lo que puede responder a flujos constantes (como tránsito interurbano o zonas de baja densidad).

Esta comparación permite distinguir comportamientos operativos heterogéneos entre peajes, lo cual es útil para ajustar políticas de gestión de tráfico o mantenimiento según la variación horaria esperada.

DISTRIBUCION DE MEDIOS DE PAGO

Totales de entrada por cobro

```
plt.figure(figsize=(10,5))
tipo_cobro_total = df['TIPO_COBRO'].value_counts()
sns.barplot(x=tipo_cobro_total.index, y=tipo_cobro_total.values)
plt.title('Distribución total de medios de pago')
plt.xlabel('Tipo de cobro')
plt.ylabel('Cantidad de registros')
plt.xticks(rotation=45)
plt.show()
```

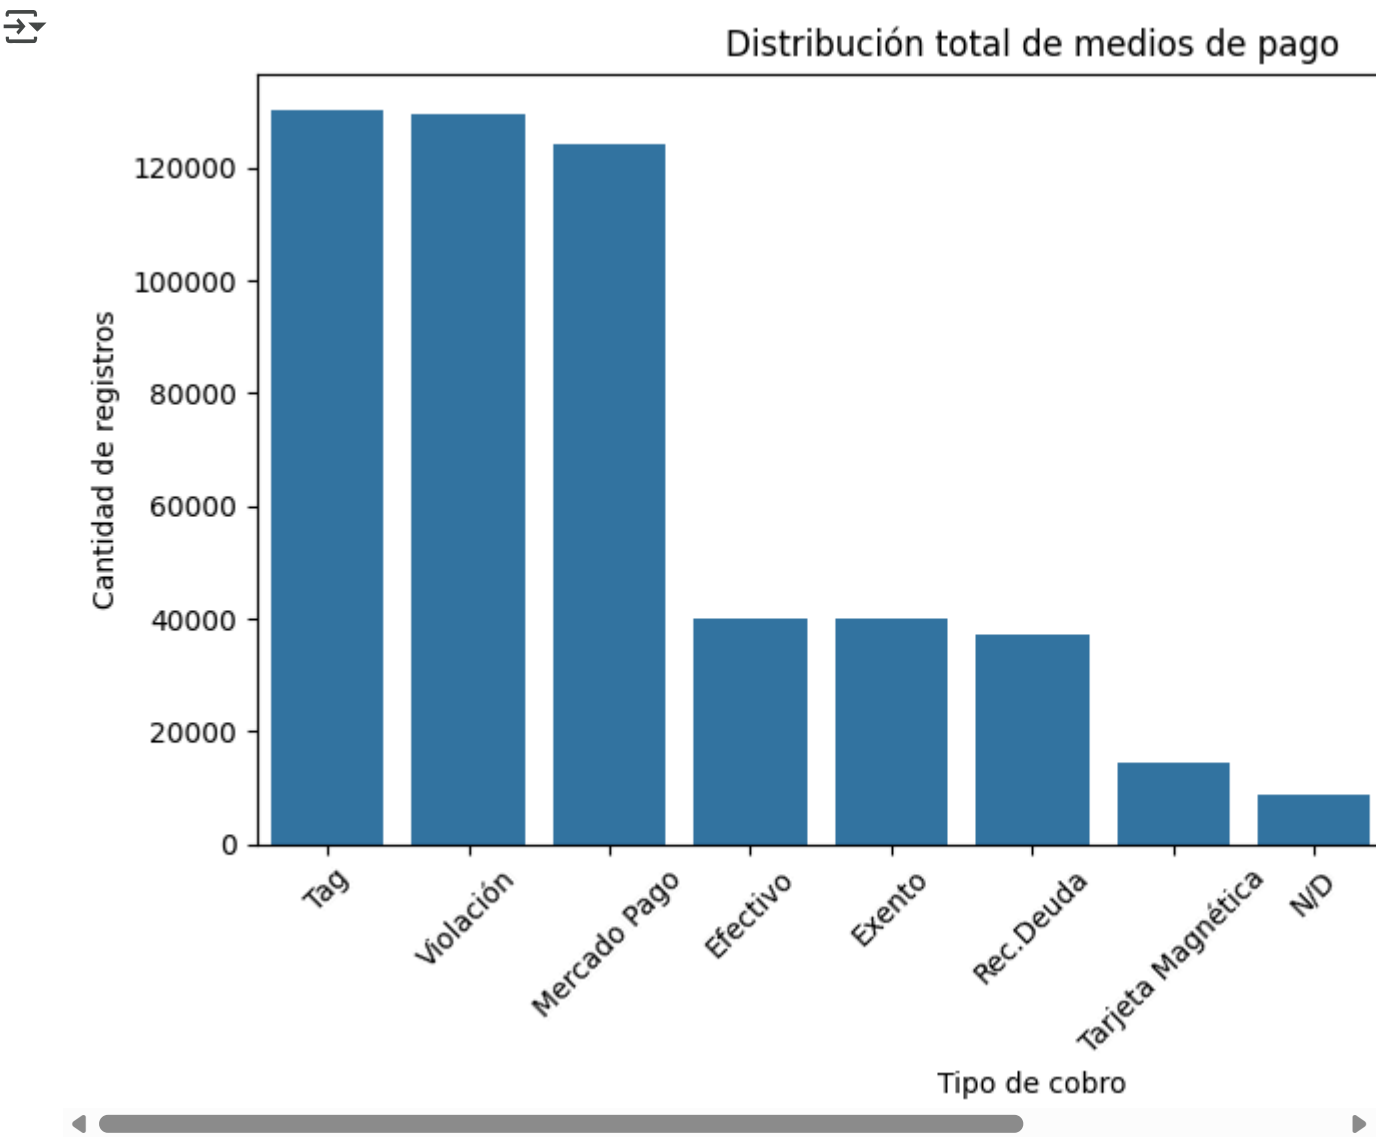

Totales de Medios de cobro por peaje

```
pasos_por_cobro_y_peaje = df.groupby(['ID_PEAJE', 'TIPO_COBRO'])['PASOS'].sum().reset

plt.figure(figsize=(16,6))
sns.barplot(data=pasos_por_cobro_y_peaje, x='ID_PEAJE', y='PASOS', hue='TIPO_COBRO')
plt.title('Distribución de medios de pago por peaje (según cantidad de pasos)')
plt.xlabel('ID Peaje')
plt.ylabel('Pasos')
plt.legend(title='Tipo de cobro')
plt.show()
```